
Trabalho Prático II: Aprendizado de máquina

Valor: 15 pontos

Data de entrega: 17 de Junho de 2026

1 Objetivo

O objetivo desse trabalho é estudar técnicas de aprendizado supervisionado e não-supervisionado, mais especificamente os algoritmos *k-Nearest Neighbors (kNN)* e *k-Means*. O trabalho é dividido em três partes. Será utilizados o conjunto de dados *NBA Rookie Stats*, que contém estatísticas de jogadores novatos da *NBA*. Ele consiste de 1.340 observações, com as seguintes variáveis (atributos):

- GP: Total de jogos disputados
- MIN: Minutos jogados
- PTS: Pontos marcados por jogo
- FGM: Arremessos convertidos
- FGA: Tentativas de arremessos
- FG%: Percentual de conversão de arremessos
- 3PMade: Arremessos de 3 pontos convertidos
- 3PA: Tentativas de arremessos de 3 pontos
- 3P%: Percentual de conversão de arremessos de 3 pontos
- FTM: Lances livres convertidos
- FTA: Tentativas de lances livres
- FT%: Percentual de conversão de lances livres
- OREB: Rebotes ofensivos
- DREB: Rebotes defensivos
- REB: Total de rebotes
- AST: Assistências
- STL: Roubos de bola
- BLK: Bloqueios
- TOV: Perdas de bola
- TARGET_5Yrs: Se a carreira do jogador durou pelo menos 5 anos na liga, tem valor 1. Caso contrário, o valor é 0.

A variável TARGET_5Yrs é a variável resposta de interesse no uso deste conjunto de dados.

2 Tarefas

O trabalho é dividido em três partes. A primeira será focada em aprendizado supervisionado e a segunda relacionada ao não-supervisionado. Você irá implementar um algoritmo de cada tipo, assim como analisar e discutir o resultado de cada aplicação.

Aprendizado Supervisionado: Na primeira parte do trabalho você deverá implementar o algoritmo *k-Nearest Neighbors* para classificar se a carreira de um jogador vai durar pelo menos 5 anos na liga ou não.

Aprendizado Não-Supervisionado: Na segunda parte você deverá implementar o algoritmo *k-Means* para agrupar os jogadores em diferentes conjuntos (clusters) usando apenas os atributos das amostras (sem utilizar a coluna de resposta TARGET_5Yrs).

Comparação de resultados: Por fim, existem várias bibliotecas prontas que implementam o *kNN*, *k-Means* e vários outros algoritmos de aprendizado de máquina. Nesta parte, você deverá implementar o trabalho usando a biblioteca *scikit-learn* do *Python* e comparar os resultados com os obtidos em sua implementação. Nesse caso, além da implementação, você deverá discutir a comparação em sua documentação.

3 Experimentos

Após concluir a implementação dos algoritmos, você irá executar os experimentos listados a seguir e reportar os resultados encontrados.

Experimentos *k-Nearest Neighbors*: Utilize o conjunto de dados separadamente para o treino (arquivo *nba_treino.csv*), que contém 80% dos dados (1.072 observações), e teste (arquivo *nba_teste.csv*), que contém o restante dos 20% (268 observações). Teste o algoritmo para valores de $k = \{2, 10, 50\}$, um outro a sua escolha. Para cada valor, você deve:

- Classificar os dados do conjunto de teste;
- Mostrar a matriz de confusão obtida;
- Computar os valores de acurácia, precisão, revocação (recall) e F1.

Apresente uma análise e discussão sobre os resultados obtidos. Compare os resultados obtidos pela sua implementação com a biblioteca *scikit-learn*.

Experimentos *k-Means*: Utilize todos os dados (ambos arquivos *nba_treino.csv* e *nba_teste.csv*). Teste o algoritmo para valores $k = \{2, 3\}$. Para cada valor, você deve:

- Reportar o valor obtido para os centróides de cada agrupamento.
- Verifique se existe alguma relação entre os agrupamentos obtidos e os rótulos originais dos dados.

Discuta sobre os resultados obtidos. Com $k=2$ o algoritmo conseguiu agrupar bem os jogadores nas duas classes de resposta originais? O que acontece para $k=3$? Compare os resultados obtidos pela sua implementação com a biblioteca *scikit-learn*.

4 Relatório

O relatório deve apresentar de forma **sucinta** o seu trabalho, explicando decisões de projeto e resultados obtidos. Deve conter os seguintes tópicos:

- **Introdução e Objetivo**
- **Metodologia:** Apresentar os algoritmos utilizados e detalhes de implementação.
- **Experimentos e Resultados:** tabelas e gráficos com as métricas propostas dos experimentos realizados. Comparação com a biblioteca *scikit-learn*.
- **Discussão:** interpretação das métricas obtidas e análise crítica dos resultados.
- **Conclusão:** síntese dos resultados obtidos em cada um dos métodos e melhores resultados para o problema.

5 Submissão

O seu trabalho deve ser implementado em *Python*. Para entrega, submeta um arquivo zip (NomeDoAluno.zip) que deve conter:

- Códigos fonte dos algoritmos desenvolvidos
- Um arquivo `readme.txt` com informações sobre como executar seu programa
- Relatório

O trabalho é em **dupla**. Não é permitido o uso de bibliotecas prontas (exceto para a parte de comparação com bibliotecas).